LAPORAN PROYEK ETS

Optimasi Alokasi Portofolio Saham LQ45 dengan Batas Risiko dan Kardinalitas



Komputasi Lunak (A)
Disusun oleh
Kelompok 4

Antika Raya	5026231034
Hans Christian Cakrawangsa	5026231130
Lailatul Fitaliqoh	5026231229

DEPARTEMEN SISTEM INFORMASI
INSTITUT TEKNOLOGI SEPULUH NOPEMBER
2026

DAFTAR ISI

DAFTAR ISI **2**
DAFTAR GAMBAR **5**
DAFTAR TABEL **6**
1. PENDAHULUAN **7**
1.1. Latar Belakang 7
1.2. Rumusan Masalah 8
1.3. Tujuan 8
1.4. Batasan Masalah 9
2. TINJAUAN PUSTAKA **10**
2.1. Saham dan Indeks LQ45 10
2.2. Return, Risiko, dan Diversifikasi Portofolio 10
2.2.1. Return dan Expected Return 10
2.2.2. Risiko dan Diversifikasi 11
2.3. Optimasi Portofolio Berkendala 11
2.4. Algoritma Metaheuristik 12
2.4.1. Genetic Algorithm (GA) 12
2.4.2. Particle Swarm Optimization (PSO) 13
2.4.3. Simulated Annealing (SA) 13
2.4.4. Differential Evolution (DE) 13
2.5. Evaluasi Kinerja 14
3. METODOLOGI PENELITIAN **15**
3.1. Alur Penelitian 15
3.2. Pengumpulan dan Prapemrosesan Data 16
3.3. Formulasi Masalah dan Penanganan Kendala 19
3.4. Implementasi Algoritma Metaheuristik 22
3.4.1. Perancangan Genetic Algorithm (GA) 22
3.4.2. Perancangan Particle Swarm Optimization (PSO) 23
3.4.3. Perancangan Simulated Annealing (SA) 24
3.4.4. Perancangan Differential Evolution (DE) 26
3.5. Skenario Eksperimen dan Metrik Evaluasi 27
3.6. Visualisasi Hasil Optimasi 30
4. HASIL DAN PEMBAHASAN **32**
4.1. Validasi Constraint 32
4.2. Analisis Hasil Genetic Algorithm (GA) 32
4.2.1. Optimasi Alokasi Dana Portofolio 32
4.2.2. Analisis Karakteristik Pencarian (Crossover dan Mutasi) pada GA 32

4.3. Analisis Hasil Particle Swarm Optimization (PSO)..... 32
4.3.1. Optimasi Alokasi Dana Portofolio Saham..... 32
Tabel 4.1 Hasil Optimasi Terbaik PSO..... 32
Tabel 4.2 Rincian Alokasi Dana Saham Portofolio Terbaik PSO..... 32
4.3.2. Analisis Konvergensi dan Konsistensi Hasil..... 34
Tabel 4.3 Kinerja PSO pada 30 Percobaan..... 34
Tabel 4.4 Hasil Verifikasi PSO terhadap Brute Force pada K=2..... 35
4.3.3. Evaluasi Kinerja Portofolio pada Data Uji..... 35
Tabel 4.5 Hasil Evaluasi Portofolio PSO pada Data Uji..... 36
4.4. Analisis Hasil Simulated Annealing (SA)..... 37
4.4.1. Optimasi Alokasi Dana Portofolio..... 37
4.4.2. Analisis Efisiensi Penurunan Suhu (Cooling Schedule) terhadap Konvergensi..... 37
4.5. Analisis Hasil Differential Evolution (DE)..... 37
4.5.1. Optimasi Alokasi Dana Portofolio Saham..... 37
Tabel 4.1 Hasil Optimasi Terbaik DE..... 37
Tabel 4.2 Rincian Alokasi Dana Saham Portofolio Terbaik DE..... 37
4.5.2. Analisis Konvergensi dan Konsistensi Hasil..... 38
Tabel 4.3 Kinerja DE pada 30 Percobaan..... 39
4.5.3. Evaluasi Kinerja Portofolio Data Uji..... 40
Tabel 4.4 Hasil Evaluasi Portofolio DE pada Data Uji..... 40
Tabel 4.5 Median Return Tahunan Data Uji..... 41
4.6. Komparasi & Diskusi Lintas Algoritma..... 42
4.6.1. Perbandingan Kinerja Portofolio Optimal (Expected Return, Risiko/Variance, dan Sharpe Ratio)..... 42
4.6.2. Perbandingan Kecepatan Komputasi dan Stabilitas Konvergensi Algoritma..... 42
4.6.3. Analisis Konvergensi Gabungan..... 42
4.6.3.1. Skenario Profil Risiko Konservatif..... 42
4.6.3.2. Skenario Profil Risiko Moderat..... 42
4.6.3.3. Skenario Prodil Risiko Agresif..... 42
4.7. Implikasi Manajerial & Strategi Investasi..... 42
5. PENUTUP..... 43
5.1. Kesimpulan..... 43
5.2. Saran..... 43
6. LAMPIRAN..... 43
DAFTAR PUSTAKA..... 44

DAFTAR GAMBAR

Gambar 3.1. Alur Penelitian..... 14
Gambar 4.1 Komposisi Bobot Saham dan Kas..... 30
Gambar 4.2 Konvergensi PSO pada Skenario Kardinalitas..... 31
Gambar 4.3 Perkembangan Nilai Portofolio PSO pada Data Uji.....33
Gambar 4.1 Alokasi Modal Portofolio Terbaik DE.....35
Gambar 4.2 Konvergensi DE pada Skenario Kardinalitas.....36
Gambar 4.3 Distribusi Expected Return DE pada 30 Percobaan.....37
Gambar 4.4 Perkembangan Nilai Portofolio DE pada Data Uji..... 38

Pakai judul 5

DAFTAR TABEL

Tabel 4.1 Hasil Optimasi Terbaik PSO.....29
Tabel 4.2 Rincian Alokasi Dana Saham Portofolio Terbaik PSO.....29
Tabel 4.3 Kinerja PSO pada 30 Percobaan.....31
Tabel 4.4 Hasil Verifikasi PSO terhadap Brute Force pada K=2.....32
Tabel 4.5 Hasil Evaluasi Portofolio PSO pada Data Uji.....33
Tabel 4.1 Hasil Optimasi Terbaik DE.....34
Tabel 4.2 Rincian Alokasi Dana Saham Portofolio Terbaik DE.....34
Tabel 4.3 Kinerja DE pada 30 Percobaan.....36
Tabel 4.4 Hasil Evaluasi Portofolio DE pada Data Uji.....37
Tabel 4.5 Median Return Tahunan Data Uji.....38

Pakai judul 6

1. PENDAHULUAN

1.1. Latar Belakang

Investasi saham memerlukan keputusan mengenai saham yang dipilih dan besarnya dana yang dialokasikan pada setiap saham. Keputusan tersebut perlu mempertimbangkan potensi pengembalian (*return*) dan risiko portofolio, termasuk hubungan perubahan return antar-saham. Erwin dan Engelbrecht (2023) menjelaskan bahwa optimasi portofolio digunakan untuk menentukan komposisi investasi dengan mempertimbangkan return, risiko, dan berbagai kendala investasi. Dalam konteks Indonesia, indeks LQ45 dapat menjadi acuan pemilihan saham karena mengukur kinerja harga 45 saham dengan likuiditas tinggi, kapitalisasi pasar besar, dan dukungan fundamental perusahaan yang baik (Bursa Efek Indonesia, t.t.-a).

Permasalahan alokasi dana menjadi lebih kompleks ketika mempertimbangkan keterbatasan modal, batas jumlah saham, dan satuan pembelian. Bursa Efek Indonesia menetapkan bahwa perdagangan saham di Pasar Reguler dan Pasar Tunai dilakukan dalam kelipatan lot, dengan satu lot terdiri atas 100 lembar saham (Bursa Efek Indonesia, t.t.-b). Akibatnya, alokasi dana harus menyesuaikan harga saham dan jumlah lot yang dapat dibeli. Sementara itu, kendala kardinalitas membatasi jumlah saham dalam portofolio, sehingga proses optimasi harus menentukan kombinasi saham sekaligus alokasi dananya. Erwin dan Engelbrecht (2023) membahas kardinalitas, batas bobot, dan lot sebagai kendala yang perlu diperhatikan dalam pengembangan model optimasi portofolio.

Metaheuristik merupakan salah satu pendekatan untuk mencari solusi pada persoalan optimasi portofolio berkendala. Tinjauan Erwin dan Engelbrecht (2023) terhadap lebih dari 140 penelitian menunjukkan penggunaan berbagai algoritma evolusioner dan kecerdasan kawanan, termasuk Genetic Algorithm (GA) dan Particle Swarm Optimization (PSO). Penelitian terbaru oleh Ashraf dkk. (2026) juga menerapkan metaheuristik dan prosedur perbaikan solusi pada model portofolio dengan kendala anggaran risiko. Temuan literatur tersebut mendukung penggunaan metaheuristik sebagai pendekatan yang layak dikaji, tetapi keunggulan suatu algoritma tetap perlu diuji pada formulasi dan kondisi eksperimen yang digunakan. Oleh karena itu, proyek ini membandingkan GA, PSO, Simulated Annealing (SA), dan Differential Evolution (DE) dengan aturan masalah serta anggaran evaluasi fitness yang sama.

Proyek ini menggunakan dataset yang terdiri atas 42 saham kandidat dengan periode data November 2021 hingga September 2026 dan modal awal Rp5.000.000. Fungsi tujuannya adalah memaksimalkan expected return portofolio dengan batas jumlah saham maksimum K = 2, 3, 5, 7, dan 10 serta pembelian dalam kelipatan lot. Batas bobot maksimum 20% dari modal awal per saham diterapkan pada skenario K = 7 dan K = 10. Volatilitas portofolio dibatasi sebesar

1,5 kali volatilitas portofolio equal-weight dari seluruh saham kandidat pada data latih. Sebagian dana diperbolehkan menjadi kas dengan asumsi return bebas risiko sebesar 5% per tahun. Ketentuan tersebut merupakan rancangan masalah proyek yang menjadi dasar perbandingan keempat algoritma.

Evaluasi portofolio perlu memperhatikan bahwa estimasi dari data historis dapat berbeda dari kondisi pada periode berikutnya. Barroso dan Saxena (2022) menunjukkan bahwa estimasi historis masukan optimasi portofolio merupakan panduan yang tidak presisi terhadap nilai yang kemudian terealisasi di luar sampel. Oleh karena itu, proyek ini merencanakan evaluasi in-sample, out-of-sample, dan walk-forward untuk menilai kualitas solusi pada data latih serta kinerjanya pada data uji. Perbandingan mencakup expected return solusi layak, pemenuhan kendala, konsistensi hasil antar-pengulangan, konvergensi, dan waktu komputasi. Melalui evaluasi tersebut, proyek ini diharapkan memberikan gambaran mengenai kemampuan keempat algoritma dalam mencari alokasi dana yang memenuhi kendala serta kinerja portofolio pada periode berikutnya.

1.2. Rumusan Masalah

1. Bagaimana memodelkan dan menyelesaikan optimasi alokasi dana saham menggunakan *Genetic Algorithm* (GA), *Particle Swarm Optimization* (PSO), *Simulated Annealing* (SA), dan *Differential Evolution* (DE) dengan kendala modal, risiko, kardinalitas, lot, dan alokasi kas?
2. Bagaimana hasil alokasi dana saham yang diperoleh dari keempat algoritma pada setiap skenario kardinalitas, serta algoritma manakah yang menghasilkan portofolio dengan *expected return* tertinggi dan tetap memenuhi batasan optimasi?
3. Bagaimana perbandingan kinerja keempat algoritma berdasarkan kualitas solusi, konsistensi hasil, konvergensi, dan waktu komputasi dengan anggaran evaluasi *fitness* yang sama?

1.3. Tujuan

1. Merumuskan dan menyelesaikan model optimasi alokasi dana saham menggunakan GA, PSO, SA, dan DE dengan kendala modal, risiko, kardinalitas, lot, dan alokasi kas.
2. Menganalisis hasil alokasi dana saham dari keempat algoritma pada setiap skenario kardinalitas serta mengidentifikasi algoritma yang menghasilkan portofolio dengan *expected return* tertinggi dan memenuhi batasan optimasi.
3. Membandingkan kinerja keempat algoritma berdasarkan kualitas solusi, konsistensi hasil, konvergensi, dan waktu komputasi dengan anggaran evaluasi *fitness* yang sama.

1.4. Batasan Masalah

1. Penelitian mencakup 42 saham kandidat dalam dataset proyek yang mengacu pada LQ45, dengan periode November 2021 hingga September 2026. Daftar saham tetap dan tidak mengikuti perubahan keanggotaan indeks selama periode penelitian.
2. Modal awal ditetapkan sebesar Rp5.000.000, tanpa *short selling* dan *leverage*. Pembelian saham dilakukan dalam kelipatan satu lot atau 100 lembar.
3. Jumlah saham dibatasi maksimum K = 2, 3, 5, 7, dan 10. Batas alokasi maksimum 20% dari modal awal per saham hanya berlaku pada K = 7 dan K = 10.
4. Optimasi memaksimalkan *expected return* dengan batas volatilitas sebesar 1,5 kali volatilitas portofolio *equal-weight* pada data latih. Kas diperbolehkan dengan asumsi return bebas risiko 5% per tahun.
5. Algoritma yang dibandingkan adalah GA, PSO, SA, dan DE, dengan evaluasi *in-sample, out-of-sample,* dan *walk-forward.*
6. Portofolio dipegang tanpa penyeimbangan ulang selama setiap periode uji. Biaya transaksi, pajak, dan selisih harga eksekusi tidak diperhitungkan.

2. TINJAUAN PUSTAKA

2.1. Saham dan Indeks LQ45

Saham merupakan instrumen keuangan yang menunjukkan kepemilikan atas suatu perusahaan. Pemegang saham dapat memperoleh pendapatan melalui dividen dan keuntungan dari kenaikan harga saham. Namun, besarnya dividen dan harga jual saham pada masa mendatang tidak dapat dipastikan, sehingga investasi saham mengandung risiko (Dahlquist & Knight, 2022).

LQ45 merupakan indeks yang mengukur kinerja harga 45 saham dengan likuiditas tinggi, kapitalisasi pasar *free float* besar, serta dukungan fundamental dan kepatuhan perusahaan yang baik. Pemilihan saham penyusun indeks mempertimbangkan likuiditas transaksi, kapitalisasi pasar, kinerja keuangan, dan aspek kepatuhan (Bursa Efek Indonesia, 2024). Karakteristik tersebut menjadikan LQ45 sebagai salah satu acuan dalam kajian investasi saham di Indonesia.

Pembelian saham perlu memperhatikan satuan perdagangan yang berlaku. Bursa Efek Indonesia menetapkan bahwa perdagangan saham di Pasar Reguler dan Pasar Tunai dilakukan dalam kelipatan lot, dengan satu lot terdiri atas 100 lembar saham (Bursa Efek Indonesia, t.t.-b). Dengan demikian, jumlah dana yang dialokasikan pada saham harus menyesuaikan harga saham dan jumlah lot yang dibeli. Ketentuan ini relevan bagi optimasi alokasi dana dengan modal terbatas karena dapat menimbulkan sisa dana yang tidak terinvestasikan.

2.2. Return, Risiko, dan Diversifikasi Portofolio

2.2.1. Return dan Expected Return

Return menunjukkan tingkat pengembalian investasi selama suatu periode. Return sederhana dihitung sebagai perubahan harga relatif terhadap harga periode sebelumnya (Palomar, 2025):

$$r_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}}$$

dengan $r_{i,t}$ sebagai return saham i pada periode t, sedangkan $P_{i,t}$ dan $P_{i,t-1}$ merupakan harga yang digunakan dalam perhitungan return pada dua periode berurutan.

Expected return merupakan nilai harapan pengembalian investasi yang diestimasi berdasarkan informasi yang tersedia. Expected return portofolio diperoleh dari penjumlahan expected return setiap aset yang dikalikan bobot alokasinya (Palomar, 2025). Untuk portofolio yang mencakup saham dan kas dengan return konstan, perhitungannya dinyatakan sebagai:

$$E(R_p) = \sum_{i=1}^{N} w_i \mu_i + w_0 r_f$$

dengan N sebagai jumlah saham kandidat, w_i sebagai bobot saham i, μ_i sebagai expected return saham, w_0 sebagai bobot kas, dan r_f sebagai return bebas risiko. Seluruh return menggunakan periode pengukuran yang sama.

2.2.2. Risiko dan Diversifikasi

Dalam kerangka *mean-variance*, risiko diukur menggunakan varians atau simpangan baku return (volatilitas). Risiko portofolio dipengaruhi oleh bobot investasi dan kovarians antar-return saham. Kovarians menggambarkan kecenderungan perubahan return dua saham secara bersama-sama (Erwin & Engelbrecht, 2023). Volatilitas portofolio dirumuskan sebagai berikut (Palomar, 2025):

$$\sigma_p = \sqrt{w^T \sum w}$$

dengan σ_p sebagai volatilitas portofolio, w sebagai vektor bobot saham, dan Σ sebagai matriks kovarians return saham. Kas dengan return yang diasumsikan konstan tidak memberikan kontribusi varians maupun kovarians.

Diversifikasi merupakan penyebaran investasi pada beberapa aset untuk mengurangi risiko melalui hubungan return antar-aset. Manfaatnya bergantung pada komposisi dan hubungan return aset yang dipilih (Erwin & Engelbrecht, 2023). Salah satu bentuk alokasi sederhana adalah portofolio *equal-weight*, yang memberikan bobot sama sebesar $1/N$ kepada setiap saham. Portofolio tersebut dapat digunakan sebagai pembanding dalam evaluasi strategi investasi (Palomar, 2025).

2.3. Optimasi Portofolio Berkendala

Optimasi portofolio merupakan proses menentukan alokasi investasi untuk mencapai tujuan tertentu dengan memenuhi sejumlah kendala. Salah satu pendekatannya adalah memaksimalkan expected return pada batas risiko yang diperbolehkan (Palomar, 2025). Untuk portofolio saham dan kas dengan return konstan, fungsi tujuannya dapat dinyatakan sebagai:

$$\max_{w,w_0} R = \sum_{i=1}^{N} w_i \mu_i + w_0 r_f$$

dengan $R = E(R_p)$, yaitu expected return portofolio. Risiko portofolio dibatasi melalui:

$$\sqrt{w^T \sum w} \leq \sigma_{max}$$

Nilai σ_{max} menunjukkan batas volatilitas yang diperbolehkan. Dengan demikian, optimasi mencari alokasi dengan expected return terbesar di antara solusi yang memenuhi batas risiko serta kendala investasi lainnya.

Kendala modal memastikan total alokasi tidak melampaui dana yang tersedia. Apabila kas diperbolehkan, jumlah bobot saham dan kas sama dengan satu. Ketentuan *long-only* mengharuskan bobot saham bernilai nonnegatif, sedangkan batas bobot membatasi proporsi investasi pada setiap saham. Kendala kardinalitas membatasi jumlah saham dengan kepemilikan positif hingga paling banyak K saham (Palomar, 2025).

Kendala lot mengharuskan pembelian dilakukan dalam kelipatan satuan perdagangan. Kombinasi kendala lot dan kardinalitas menyebabkan keputusan optimasi mencakup pemilihan saham sekaligus penentuan jumlah pembeliannya. Kandidat yang direpresentasikan sebagai vektor numerik dapat diterjemahkan melalui dekoder menjadi keputusan investasi, kemudian dievaluasi berdasarkan fungsi tujuan dan pemenuhan kendalanya (Erwin & Engelbrecht, 2023).

Salah satu pendekatan penanganan kendala adalah aturan kelayakan Deb. Pendekatan ini mengutamakan solusi layak dibandingkan solusi tidak layak. Dua solusi layak dibandingkan berdasarkan fungsi tujuan, sedangkan dua solusi tidak layak dibandingkan berdasarkan besar pelanggaran kendala (Deb, 2000). Pada persoalan maksimasi expected return, solusi layak dengan expected return lebih tinggi dinilai lebih baik.

2.4. Algoritma Metaheuristik

2.4.1. *Genetic Algorithm* (GA)

Genetic Algorithm (GA) merupakan algoritma berbasis populasi yang meniru prinsip evolusi dan seleksi alam. Setiap kandidat solusi direpresentasikan sebagai kromosom, sedangkan sekumpulan kromosom membentuk populasi. Kualitas kandidat dinilai melalui fungsi evaluasi untuk menentukan individu yang dipertahankan atau digunakan dalam pembentukan generasi berikutnya (Katoch dkk., 2021).

Proses GA meliputi inisialisasi populasi, evaluasi, seleksi, *crossover*, mutasi, dan pembentukan populasi berikutnya. Seleksi menentukan kandidat induk, *crossover* menggabungkan informasi dari induk, sedangkan mutasi memberikan perubahan acak untuk menjaga keragaman pencarian. Strategi elitisme dapat digunakan untuk mempertahankan sejumlah individu terbaik. Proses tersebut diulang hingga kriteria penghentian terpenuhi. Kinerja GA dipengaruhi oleh

representasi solusi, ukuran populasi, serta pengaturan operator seleksi, crossover, dan mutasi (Katoch dkk., 2021).

2.4.2. *Particle Swarm Optimization* (PSO)

Particle Swarm Optimization (PSO) merupakan algoritma berbasis populasi yang diperkenalkan oleh Kennedy dan Eberhart (1995). Algoritma ini terinspirasi oleh perilaku sosial kelompok, seperti kawanan burung. Setiap kandidat solusi disebut partikel dan memiliki posisi serta kecepatan dalam ruang pencarian. Posisi menunjukkan kandidat solusi, sedangkan kecepatan menentukan perubahan posisinya.

Pencarian PSO memanfaatkan posisi terbaik yang pernah ditemukan oleh setiap partikel (*personal best*) dan informasi posisi terbaik dari kelompoknya. Pada bentuk dengan komunikasi seluruh kawanan, acuan kelompok tersebut disebut *global best*. Setiap iterasi memperbarui kecepatan dan posisi partikel, mengevaluasi kandidat baru, kemudian memperbarui catatan posisi terbaik. Dengan mekanisme ini, partikel menggabungkan pengalaman pribadi dan informasi kelompok untuk mengarahkan pencarian. Perilakunya dipengaruhi oleh ukuran kawanan serta pengaturan pembaruan kecepatan dan posisi (Kennedy & Eberhart, 1995).

2.4.3. *Simulated Annealing* (SA)

Simulated Annealing (SA) merupakan metode pencarian yang terinspirasi oleh proses pendinginan material untuk mencapai keadaan berenergi rendah. Dalam optimasi, keadaan material dianalogikan sebagai kandidat solusi, sedangkan energi berkaitan dengan nilai fungsi yang dioptimalkan. Berbeda dari metode berbasis populasi, SA memperbarui satu solusi aktif melalui pembentukan solusi tetangga (Kirkpatrick dkk., 1983).

Solusi tetangga yang lebih baik diterima, sedangkan solusi yang lebih buruk masih dapat diterima dengan probabilitas tertentu. Peluang penerimaan tersebut dipengaruhi oleh besarnya penurunan kualitas dan parameter suhu. Pada suhu tinggi, pencarian lebih terbuka terhadap perpindahan menuju solusi yang lebih buruk. Ketika suhu menurun, penerimaan tersebut semakin terbatas. Mekanisme ini memungkinkan pencarian keluar dari optimum lokal, tetapi keberhasilannya dipengaruhi oleh pembentukan tetangga, suhu awal, jadwal pendinginan, dan kriteria penghentian (Kirkpatrick dkk., 1983).

2.4.4. *Differential Evolution* (DE)

Differential Evolution (DE) merupakan algoritma evolusioner berbasis populasi yang dikembangkan untuk optimasi pada ruang kontinu.

DE membentuk kandidat baru dengan memanfaatkan selisih antarvektor dalam populasi. Selisih tersebut memberikan informasi arah dan besar perubahan dalam proses pencarian (Storn & Price, 1997).

Tahapan utama DE mencakup inisialisasi, mutasi diferensial, crossover, dan seleksi. Pada strategi *DE/rand/1/bin*, vektor mutan dibentuk dengan menambahkan satu selisih dua vektor yang telah dikalikan faktor skala F pada sebuah vektor dasar yang dipilih secara acak. Ketiga vektor dipilih dari individu berbeda dan berbeda dari individu target. Crossover binomial kemudian menggabungkan komponen vektor mutan dan target untuk menghasilkan kandidat uji. Kandidat uji menggantikan target apabila memberikan hasil evaluasi yang lebih baik atau setara menurut aturan seleksi. Parameter penting DE meliputi ukuran populasi, faktor skala F, dan probabilitas crossover CR (Storn & Price, 1997).

2.5. Evaluasi Kinerja

Evaluasi optimasi portofolio perlu membedakan kemampuan algoritma dalam mencari solusi dan kinerja portofolio pada periode berikutnya. Evaluasi in-sample menggunakan data yang menjadi dasar pembentukan portofolio, sedangkan evaluasi out-of-sample menggunakan data periode setelahnya yang tidak digunakan dalam pembentukan solusi. Pemisahan tersebut diperlukan agar penilaian tidak hanya mencerminkan kecocokan terhadap data latih (Palomar, 2025).

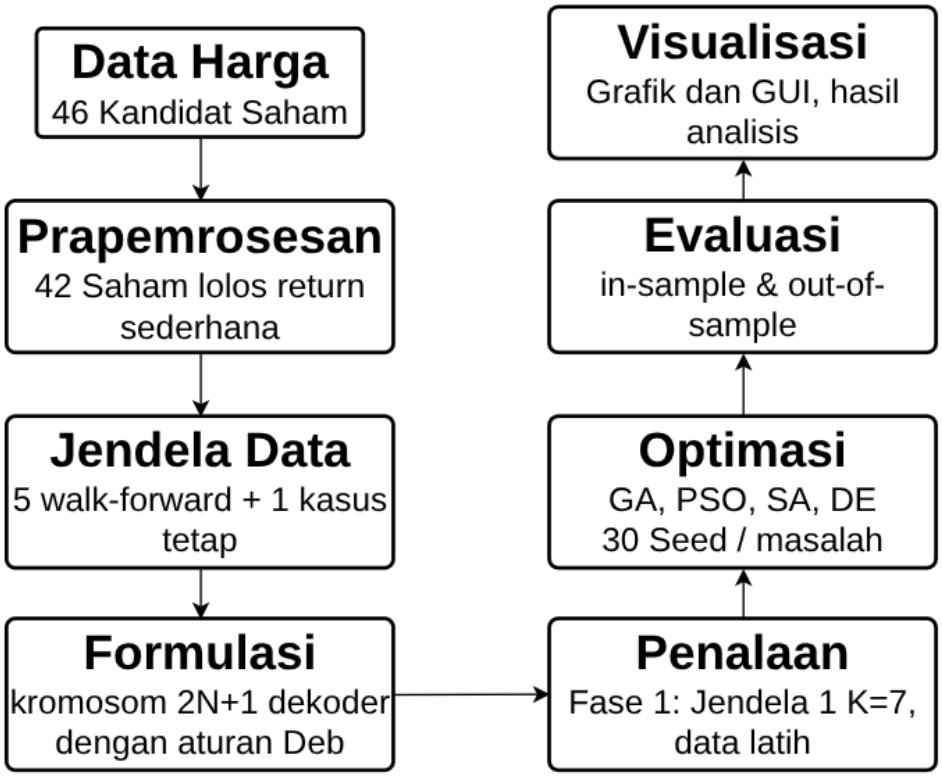
Evaluasi *walk-forward* dilakukan dengan membentuk portofolio menggunakan suatu jendela data latih, kemudian mengujinya pada periode berikutnya. Jendela tersebut digeser ke depan dan proses diulang menggunakan informasi yang tersedia pada setiap waktu pembentukan portofolio. Dengan demikian, walk-forward merupakan pengujian out-of-sample secara berurutan, bukan pengujian menggunakan seluruh data sekaligus (Palomar, 2025).

Dalam proyek ini, kinerja algoritma dibandingkan berdasarkan kualitas solusi, tingkat kelayakan, konsistensi hasil, konvergensi, dan waktu komputasi. Kualitas solusi dinilai melalui expected return solusi yang memenuhi seluruh kendala, sedangkan tingkat kelayakan menunjukkan persentase run yang menghasilkan solusi layak. Konsistensi hasil dilihat dari variasi kualitas solusi antar-seed menggunakan rata-rata, median, dan simpangan baku. Konvergensi diamati melalui perkembangan expected return terbaik dari solusi layak terhadap jumlah evaluasi fitness. Waktu komputasi digunakan untuk membandingkan durasi penyelesaian setiap run pada lingkungan komputasi yang sebanding.

3. METODOLOGI PENELITIAN

3.1. Alur Penelitian

Penelitian ini dilakukan dalam 8 tahapan, mulai dari pengumpulan data harga saham hingga analisis hasil optimasi. Urutan tahapan tersebut digambarkan dalam diagram alir berikut:



Gambar 3.1. Alur Penelitian

Gambar tersebut menunjukkan bahwa algoritma optimasi hanya menerima data latih, sedangkan data uji baru dipakai pada tahap awal evaluasi. Setiap tahap dijelaskan sebagai berikut:

1. **Pengumpulan Data Harga**
   Harga harian 46 kandidat saham konstituen LQ45 diunduh dari Yahoo Finance menggunakan *library* yfinance untuk periode 1 Oktober 2021 sampai 1 Oktober 2026. Dua jenis harga disimpan: *Adjusted Close* untuk menghitung *return,* dan *Close* tanpa penyesuaian dividen untuk menghitung harga satu lot.
2. **Pemrosesan**
   Saham dengan data kosong lebih dari 5% dibuang, sehingga tersisa 42 saham. Kekosongan hingga 3 hari diisi dengan harga sebelumnya (*forward fill)*. Return sederhana harian dihitung dari *Adjusted Close* dan menghasilkan 1.162 hari return.

3. **Pembentukan Jendela Data**
   Data dibagi menjadi 5 jendela walk-forward (latih 504 hari, uji 126 hari) dan satu kasus tetap (latih sampai 30 September 2025). Pada setiap jendela, *expected return* μ, matriks kovarians $\sum$, harga beli, dan batas risiko σ_{max} dihitung hanya dari data latih.
4. **Formulasi Masalah**
   Masalah dirumuskan sebagai maksimasi *expected return* dengan kendala risiko, kardinalitas, lot, batas bobot, dan alokasi kas. Keempat Algoritma tersebut memakai representasi kromosom, dekoder, dan fungsi evaluasi yang sama agar perbandingan adil.
5. **Penalaan Parameter**
   Parameter algoritma diuji pada grid kecil menggunakan data latih jendela pertama saja (K=7, batas risiko 1,5 kali), lalu parameter dipilih dan dibekukan sebelum perbandingan utama.
6. **Optimasi**
   GA, PSO, SA, dan DE dijalankan pada setiap masalah dengan 30 seed dan anggaran 20.000 evaluasi fitness per run.
7. **Evaluasi**
   Hasil dinilai secara *in-sample* (*return*, kelayakan, konsistensi, konvergensi, waktu komputasi) dan *out-of-sample* (portofolio dipegang tanpa perubahan selama periode uji).
8. **Visualisasi dan Analisis**
   Hasil ditampilkan sebagai kurva konvergensi, *boxplot*, bobot portofolio, dan nilai portofolio pada data uji yang dapat dianalisis dalam bentuk GUI menggunakan tools streamlit.

3.2. Pengumpulan dan Prapemrosesan Data

Data penelitian merupakan harga harian saham konstituen LQ45 dari Yahoo Finance yang diunduh dengan pustaka yfinance. Daftar awal berisi 46 ticker berakhiran .JK untuk periode 1 Oktober 2021 sampai 1 Oktober 2026. Dua seri harga diunduh dengan pengaturan auto_adjust=False, masing-masing untuk fungsi yang berbeda:

1. *Adjusted Close* dipakai untuk menghitung return historis, *expected return* μ, matriks kovarians $\sum$, karena sudah memuat dividen dan *stock split*.
2. *Close* tanpa penyesuaian dividen dipakai sebagai harga beli untuk menghitung jumlah lot, karena lot dibeli pada harga nyata di bursa.

Tahap prapemrosesan dilakukan dengan urutan berikut:

1. Hari tanpa data sama sekali (hari libur) dibuang karena tidak ada kondisi yang memenuhi pada hari tersebut.

2. Ticker dengan data kosong lebih dari 5% dibuang, yaitu AMMN (35,7%), GOTO (10,9%), MBMA (31,9%), dan PGEO (29,0%). Dengan demikian saham tersisa 42 saham.
3. Kekosongan hingga 3 hari diisi dengan harga sebelumnya *(forward-fill)*, lalu baris yang masih kosong dibuang. Sebanyak 35 hari awal dibuang karena MTEL baru memiliki data pada akhir periode awal unduhan. Hasil akhirnya adalah 1.163 hari harga (22 November 2021 sampai 30 September 2026) dan 1.162 hari *return.*
4. Return dihitung sebagai return sederhana dari *Adjusted Close* (bukan *log-return*) sehingga definisi *return* pada fungsi tujuan dan pada evaluasi data uji sama.
5. Dilakukan pemeriksaan *noise* / anomali data. Tidak ditemukan perubahan harga mentah lebih dari 35% yang tidak tercermin pada *Adjusted Close*, dan tidak ada *return* harian dengan nilai mutlak diatas 35%. Delapan peristiwa *stock split* tercatat (AKRA, BBCA, BBNI, BMRI, BRPT dua kali, HRUM, dan ISAT) dan tidak ada data yang dihapus karena hal tersebut.

Pembagian Data dan Estimasi Parameter

Pembagian data memakai skema *walk-forward.* Setiap jendela terdiri dari 504 hari bursa data latih (sekitar dua tahun) untuk mengestimasi μ, $\sum$, dan σ_{max}, diikuti dengan 126 hari bursa data uji (sekitar 6 bulan) untuk menilai kinerja portofolio. Jendela digeser maju 126 hari sehingga terbentuk 5 jendela. Selain hal itu, dibentuk satu kasus tetap yang memakai seluruh data latih sampai 30 September 2025 (923 hari) dan data uji sesudahnya (239 hari), terutama untuk perbandingan konvergensi antar-algoritma.

Tabel 3.1 Jendela Data Latih dan Data Uji

Jendela	Periode latih	Periode uji	Hari latih / uji	Volatilitas 1/N	σ_max (1,5×)	Return 1/N di data uji
1	23 Nov 2021 – 14 Des 2023	15 Des 2023 – 9 Jul 2024	504 / 126	0,1365	0,2048	+4,8%
2	7 Jun 2022 – 9 Jul 2024	10 Jul 2024 – 9 Jan 2025	504 / 126	0,1318	0,1976	−7,4%
3	1 Des 2022 – 9 Jan 2025	10 Jan 2025 – 31 Jul 2025	504 / 126	0,1308	0,1962	+6,0%
4	14 Jun 2023 – 31 Jul 2025	1 Agu 2025 – 3 Feb 2026	504 / 126	0,1739	0,2609	+10,9%

5	15 Des 2023 – 3 Feb 2026	4 Feb 2026 – 20 Agu 2026	504 / 126	0,1811	0,2717	−7,5%
Tetap	23 Nov 2021 – 30 Sep 2025	1 Okt 2025 – 30 Sep 2026	923 / 239	0,1593	0,2390	−8,1%

Seluruh statistik dihitung hanya dari baris data latih. Potongan kode berikut menunjukkan pembentukan satu jendela:

Tabel 3.2 Kode Pembentukan Jendela dan Estimasi Statistik

```
latih = return_df.iloc[i_latih_awal:i_latih_akhir + 1]
uji = return_df.iloc[i_latih_akhir + 1:i_uji_akhir + 1]

mu = latih.values.mean(axis=0) * 252
cov = np.cov(latih.values.T, ddof=1) * 252

eq = np.full(n, 1.0 / n)
vol = float(np.sqrt(eq @ cov @ eq))
sigma_max = {m: m * vol for m in config.SIGMA_MULT}

harga_beli =
harga_raw_df.loc[tgl_akhir_latih].values.astype(float)
```

Expected return μ dihitung sebagai rata-rata return harian dikali dengan 252 hari bursa, Σ adalah kovarians sampel return harian dikali 252. Volatilitas portofolio equal-weight dari 42 saham (vol) menjadi acuan batas risiko, yaitu $\sigma_{max} = 1,5 \times vol$. Nilai eigen minimum Σ positif pada semua jendela (paling kecil $1,98 \times 10^{-2}$) sehingga Σ definit positif. Harga beli (harga_beli) adalah Close tanpa penyesuaian dividen pada hari terakhir data latih, yang setara dengan membeli pada penutupan hari tersebut dan menahannya selama periode uji. Return uji disimpan terpisah dan tidak dimasukkan ke dalam objek *Problem* yang diberikan kepada algoritma sehingga data uji tidak mungkin bocor ke proses optimasi.

Untuk catatan keterbatasan, *Close* dari Yahoo Finance sudah disesuaikan untuk stock split. Untuk saham yang melakukan split setelah tanggal beli suatu jendela (ISAT 4:1 pada 14 Oktober 2024 untuk jendela 1 dan 2, serta BRPT sebesar 1,0016 untuk jendela 1), harga satu lot tampak lebih murah daripada harga transaksi sebenarnya saat itu.

3.3. Formulasi Masalah dan Penanganan Kendala

Pada hal ini menjelaskan bagaimana masalah alokasi portofolio dimodelkan dan bagaimana satu kromosom diubah menjadi portofolio yang valid. Bagian ini dipakai bersama oleh keempat algoritma pada Subbab 3.4, sehingga perbedaan hasil hanya berasal dari strategi pencariannya.

Pada tahap awal model optimasi, dana awal D = Rp5.000.000 dibagi kedalam N = 42 saham dan kas. Variabel keputusan adalah jumlah lot n_i (bilangan bulat tak negatif) untuk saham ke-i. Satu lot berisi 100 lembar sehingga nilai pembelian saham ke-i adalah $v_\mathrm{i} = 100 \cdot n_\mathrm{i} \cdot P_\mathrm{i}$, dengan P_i harga Close mentah pada hari terakhir data latih. Bobot saham $w_\mathrm{i} = v_\mathrm{i} / D$, dan sisa dana menjadi kas $w_0 = 1 - \Sigma w_\mathrm{i}$ yang diasumsikan memperoleh suku bunga bebas risiko $r_f = 5\%\ per\ tahun.$

Fungsi Tujuan:

$$max_{n,z}\ R = \sum_{i=1}^{N} w_i \boldsymbol{\mu}_I + w_0 r_f \qquad (Maksimalkan\ Expected\ Return)$$

Dengan Kendala / *Constraint* :

1. $\sigma(n) = \sqrt{w^T \sum w} \le \sigma_{max}$ $\qquad (batas\ risiko)$
2. $\sum_{i=1}^{N} vi \le D,\ w_0 = 1 - \sum_{i=1}^{N} w_i \ge 0$ $\qquad (kendala\ dana)$
3. $|\{i: n_i \ge 1\}| \le K$ $\qquad (kardinalitas)$
4. $w_i \le 0,20\ (hanya\ untuk\ K \ge 7)$ $\qquad (batas\ bobot)$
5. $n_i \in \mathbb{Z} \ge 0$ $\qquad (integer)$

Batas risiko σ_{max} ditetapkan sebagai 1,5 kali volatilitas portofolio equal-weight pada data latih (Tabel 3.1). Batas bobot 20% per saham hanya diberlakukan untuk K ≥ 7. Pada K yang lebih kecil, batas tersebut membatasi dana yang dapat diinvestasikan paling banyak 20% × K dari modal (misalnya K = 3 hanya 60%), sehingga sisanya terpaksa menjadi kas dan perbandingan antar-K tidak lagi setara . Kardinalitas K diuji pada nilai {2,3,5,7,10}. Tidak ada penjualan kosong *(short selling), leverage,* biaya transaksi, ataupun penyeimbangan ulang; portofolio dibeli sekali pada akhir periode latih dan ditahan sampai akhir periode uji *(buy-and-hold)*.

Representasi kromosom pada setiap solusi dikodekan sebagai vektor konkret berpanjang 2N+1 = 85 gen bernilai pada [0,1]:

Tabel 3.3 Struktur Kromosom

Gen	Jumlah	Fungsi
Kunci pemilihan	N = 42	Menentukan K saham yang dipilih (K kunci terbesar)
Bobot mentah	N = 42	Proporsi relatif dana antar-saham terpilih
Gen kas g_0	1	Fraksi dana yang sengaja disimpan sebagai kas

Pemisahan kunci dan bobot membuat kendala kardinalitas terpenuhi secara otomatis tanpa adanya penalti. Gen kas g_0 diperlukan karena pada K kecil pada batas risiko hanya dapat dipenuhi dengan menyimpan sebagian dana sebagai kas: pada kasus tetap, volatilitas saham tunggal terendah adalah 0,226 sedangkan σ_{max} hanya 0,239 sehingga hampir tidak ada kombinasi saham penuh yang layak.

Dekoder Kromosom bersifat deterministik dan mengubah kromosom menjadi sebuah lot bulat. Dengan dekoder ini, batas dana, kas tidak negatif, kardinalitas, batas bobot, dan bilangan bulat dijamin terpenuhi oleh konstruksi, namun hanya batas risiko yang dapat dilanggar. Tahapnya:

1. Saham yang harga satu lotnya melebihi batas dana per saham (D*cap) dikeluarkan dari kandidat.
2. K saham dengan kunci terbesar dipilih dari kandidat.
3. Bobot mentah saham terpilih dinormalkan sehingga jumlahnya (1-g_0)
4. Jika batas bobot berlaku (K≥ 7), bobot di atas 20% dipotong dan kelebihannya dibagikan ke saham yang terpilih lain secara proporsional dan kelebihan yang tidak dapat dibagikan menjadi kas.
5. Jumlah lot dihitung dengan pembulatan ke bawah: $n_i = \lfloor w_i \cdot D \,/\, (100 \cdot P_i) \rfloor$. Sisa dana akibat pembulatan menjadi kas.

Tabel 3.4 Kode Dekoder

```
layak = P.layak_beli
urut = np.argsort(-np.where(layak, keys, -np.inf),
axis=1)[:, :P.K]
pilih = np.zeros((M, N), bool)
np.put_along_axis(pilih, urut, True, axis=1)
```

```
r = np.where(pilih, raw, 0.0)
frac = r / r.sum(1, keepdims=True)
w = (1.0 - g0)[:, None] * frac

if P.cap < 1.0:
   w = _cap_redistribute(w, pilih, P.cap)

lots = np.floor(w * P.D / P.harga_lot).astype(np.int64)
w_akhir = lots * P.harga_lot / P.D
kas = np.maximum(1.0 - w_akhir.sum(1), 0.0)
```

Penanganan Pelanggaran Risiko menggunakan Aturan Deb pada kendala risiko $\sigma \leq \sigma_{max}$, bukan fungsi penalti sehingga tidak ada koefisien penalti yang harus digunakan. Pelanggaran dihitung sebagai $viol = max(0, \sigma - \sigma_{max})$. Dua solusi dibandingkan dengan aturan:

1. Solusi layak selalu mengalahkan solusi tidak layak.
2. Jika keduanya layak, yang menang adalah yang R-nya lebih besar.
3. Jika keduanya tidak layak, yang menang adalah yang viol-nya lebih kecil.

Tabel 3.5 Kode Aturan Deb

```
def deb_better(a, b):
   (Ra, va), (Rb, vb) = a, b
   if va <= 0 and vb <= 0:
       return Ra > Rb
   if va <= 0:
       return True
   if vb <= 0:
       return False
   return va < vb
```

Aturan ini digunakan untuk seleksi turnamen GA, pembaruan *pbest* dan *gbest* PSO, penerimaan tetangga SA, dan seleksi *greedy* DE.

Semua algoritma memanggil fungsi tujuan hanya melalui kelas Evaluator. Kelas ini mendekode kromosom, menghitung R, σ, dan viol, menyimpan solusi yang terbaik menurut aturan dari Deb, dengan mencatat riwayat konvergensi setiap 200 evaluasi, dan menghitung evaluasi dengan satu vektor kromosom sebagai satu evaluasi. Jika jumlah evaluasi akan melampaui anggaran, Evaluator melempar pada fungsi AnggaranHabis. Anggaran setiap run adalah 20.000

evaluasi untuk semua algoritma sehingga perbandingan antar-algoritma dilakukan dengan biaya komputasi yang sama dan tidak bergantung pada kecepatan implementasi masing-masing.

Tabel 3.6 Kode Evaluator

```
def evaluate(self, X):
    if self.n_eval + len(X) > self.budget:
        raise AnggaranHabis
    lots, w, kas = decode_batch(X, self.P)
    R = w @ self.P.mu + kas * self.P.rf
    sigma = np.sqrt(np.einsum("ij,jk,ik->i", w, self.P.cov,
w))
    viol = np.maximum(0.0, sigma - self.P.sigma_max)
    # perbarui solusi terbaik (aturan Deb), n_eval, dan
riwayat
    return R, sigma, viol
```

Populasi awal dibuat acak seragam pada [0,1], dengan g_0 pada [0; 0,5]. Pada keempat algoritma, 10% individu awal disemai dengan heuristik: kunci = skor (μ_i − r_f)/σ_i yang dinormalkan ke [0,1] ditambah derau N(0; 0,05), bobot mentah U(0,3; 1), dan g_0 ~ U(0; 0,1). Jumlah individu tersemai mengikuti proporsi yang sama: GA 10 dari 100 (40 dari 400 pada konfigurasi terpilih), PSO 4 dari 40, DE 10 dari 100, dan SA memulai dari satu solusi tersemai. Perlakuan awal yang sama ini menjaga agar perbedaan hasil berasal dari strategi pencarian, bukan dari kualitas populasi awal.

3.4. Implementasi Algoritma Metaheuristik

3.4.1. Perancangan *Genetic Algorithm* (GA)

GA mempertahankan populasi 100 kromosom yang berevolusi melalui seleksi, pindah silang, mutasi, dan elitisme. Dengan anggaran 20.000 evaluasi, GA menjalani 200 generasi (100 evaluasi populasi awal + 199 * 100 evaluasi anak).

Tabel 3.7 Parameter GA

Parameter	Nilai
Ukuran populasi	400
Jumlah generasi (anggaran 20.000)	50(400+49*400)
Seleksi	Turnamen, k = 3, berdasarkan peringkat

	Deb
Pindah silang	SBX, peluang 0,9, η = 15, pada seluruh vektor
Mutasi bobot dan g_0	Gaussian, σ = 0,1, peluang 2/N per gen
Mutasi kunci	Tukar, peluang 0,2
Elitisme	2 individu terbaik
Individu awal tersemai	40

Langkah GA:

1. Bangun populasi awal, 10 individu akan disemai dengan heuristik skor $(\mu_i - r_f)/\sigma_i$ dan sisanya acak.
2. Evaluasi populasi dan urutkan dengan aturan Deb.
3. Pilih orang tua dengan seleksi turnamen berukuran 3.
4. Lakukan SBX pada pasangan orang tua untuk menghasilkan 2 anak.
5. Mutasi gen bobot mentah dan g_0 dibubuhi derau Gaussian, sedangkan mutasi tukar menukar kunci saham terpilih dengan kunci saham tidak terpilih yang masih terjangkau agar komposisi saham dapat berubah. Nilai gen dipotong ke [0,1].
6. Evaluasi anak, lalu ganti 2 anak terburuk dengan 2 individu elit generasi sebelumnya.
7. Ulangi langkah ke 3-6 sampai anggaran habis.

Mutasi tukar diperlukan karena kunci bersifat ordinal: perubahan kecil pada kunci hanya berpengaruh jika urutannya berubah melewati batas K sehingga mutasi Gaussian biasa jarang mengubah himpunan saham.

3.4.2. Perancangan *Particle Swarm Optimization* (PSO)

PSO memperbarui posisi sejumlah partikel (40) berdasarkan kecepatan yang dipengaruhi posisi terbaik pribadi (*pbest)* dan posisi terbaik kawanan *(gbest)*. Dengan 20.000 evaluasi, PSO menjalani 500 iterasi (40 + 499*40).

$$v_j^{t+1} = w.v_j^t + c_1 r_1 (pbest_j - x_j^t) + c_2 r_2 (gbest_j - x_j^t)$$

$$x_j^{t+1} = x_j^t + v_j^{t+1}$$

Kecepatan dipotong pada $\pm v_{max}$, posisi dipotong ke [0,1], dan kecepatan komponen yang menyentuh batas dinolkan. Pembaruan *pbest* dan *gbest* memakai aturan Deb. Kecepatan awal diambil seragam dari $U(-v_{max}, v_{max})$.

Parameter PSO ditala pada Fase 1 dengan menjalankan grid search pada jendela 1, K=7, σ_{max} $1,5\,kali$, dan seed 100-129 (diluar seed eksperimen utama 0-29). Penalaan memakai populasi awal yang disemai seperti pada Subbab 3.3, sehingga seluruh algoritma ditala dalam kondisi yang sama

Tabel 3.8 Parameter PSO

Parameter	PSO awal	PSO terpilih
Ukuran kawanan	40	40
Bobot inersia w	0,7	1,0
Koefisien $c_1 = c_2$	1,5	2,5
Kecepatan maksimum v_max	0,2	0,2
Jumlah iterasi	500	500
Individu awal tersemai	4	4

Penalaan dilakukan dalam 3 tahap:

A. Memindai $w \in \{0,4;\ ...;\ 0,9\} \times c \in \{1,0;\ 1,5;\ 2,0\}$ $(21\ titik)$
B. Perluasan satu kali karena nilai terbaik berada di tepi $w \in \{0,2;\ 0,3\},\ c \in \{0,5;\ 2,5;\ 3,0\};\ 14\ titik\ tambahan)$;
C. Memindai $v_{max} \in \{0,05;\ 0,1;\ 0,2;\ 0,5;\ 1,0\}\ pada\ (w, c)$ terbaik (4 titik tambahan). Total 39 titik * 30 seed = 1.170 run.

Kriteria: median R tertinggi; bila selisih ≤ 0,001 dipilih simpangan baku terkecil. Konfigurasi terpilih memiliki median R = 0,4396 dibanding 0,4358 pada parameter awal (Mann–Whitney p = 0,002). Nilai w = 1,0 adalah batas praktis atas (w > 1 tidak meredam kecepatan) sehingga tidak diperluas. Hasil dibekukan pada hasil/csv/fase1_parameter_beku.json.

3.4.3. Perancangan *Simulated Annealing* (SA)

SA berbeda dari ketiga algoritma lain karena hanya memelihara satu solusi yang diperbarui melalui langkah tetangga *(neighbor move)*. Solusi

awal dibuat dengan init_population (satu individu tersemai). Setiap langkah memilih 1 dari 3 gerakan.

Tabel 3.9 Gerakan Tetangga SA

Gerakan	Peluang	Efek
Tukar kunci	0,35	Menukar saham terpilih dengan saham tak terpilih
Ubah gen kas	0,20	g_0 += N(0; 0,1)
Pindah bobot	0,45	Memindahkan bobot mentah δ ~ N(0; 0,1) antara dua saham terpilih (jumlah tetap)

Penerimaan tetangga mengikuti aturan Deb yang dilengkapi kriteria Metropolis:

1. Tetangga yang lebih baik menurut aturan Deb selalu diterima.
2. Solusi layak tidak pernah ditukar dengan solusi tidak layak.
3. Jika keduanya layak, tetangga yang lebih buruk diterima dengan peluang $exp(\frac{\Delta R}{T_R \cdot T})$
4. Jika keduanya tidak layak, peluang penerimaan didasarkan pada selisih viol: $exp(\frac{-\Delta viol}{T_v \cdot T})$

Skala $(T_R = max(|R_0| \cdot 0,05;\ 10^{-4})$ dan $T_v = max(\sigma_max \cdot 0,05;\ 10^{-5})$ menyamakan satuan R dan viol terhadap suhu T. Suhu awal T_0 dikalibrasi otomatis dari 30 gerakan tetangga contoh dengan pencarian biner sampai rata-rata peluang penerimaan sekitar 0,80 (cadangan $T_0 = 1,0$ bila tidak ada gerakan yang memburuk). Suhu kemudian diturunkan secara geometrik sampai $T_{akhir} = 0,001 \cdot T_0$ selama sisa anggaran. Evaluasi kalibrasi dihitung dalam anggaran yang sama sehingga langkah pencarian sebenarnya sekitar 19.969 (1 evaluasi awal + 30 kalibrasi).

Tabel 3.10 Kode Penjadwalan Suhu SA

```
T_end = T0 * prm["T_end_ratio"]
remaining_steps = budget - ev.n_eval
```

```
alpha = (T_end / T0) ** (1.0 / remaining_steps)
T = T0
while ev.n_eval < budget:
   y = generate_neighbor(x, P, rng, ...)
   R_new, sigma_new, v_new = ev.evaluate(y)
   if accept_neighbor(R_new, v_new, R_cur, viol_cur,
T_R * T, T_v * T, rng):
       x, R_cur, viol_cur = y, R_new, v_new
   T = max(T_end, T * alpha)
```

Pada Fase 1, SA ditala pada dua parameter: peluang penerimaan awal yang menentukan T_0 (target_acceptance $\in$ {0,5; 0,8; 0,95}) dan laju pendinginan yang dinyatakan sebagai rasio suhu akhir terhadap awal ($T_{akhir}/T_0 \in \{10^{-2}; 10^{-3}; 10^{-4}\}$, diperluas ke 10^{-5} karena terbaik di tepi), total 12 titik × 30 seed. Konfigurasi terpilih: peluang penerimaan awal 0,8 dan $T_{akhir} = 10^{-4} \cdot T_0$. Median R 0,4370 dibanding 0,4358 pada parameter awal ($T_{akhir} = 10^{-3} \cdot T_0$), selisih tidak bermakna (p = 0,33): SA relatif tidak sensitif terhadap kedua parameter ini pada rentang yang diuji.

3.4.4. Perancangan *Differential Evolution* (DE)

DE memakai varian DE/rand/1/bin. Untuk setiap kromosom target, dipilih 3 kromosom donor berbeda (a, b, c) selain target, lalu dibentuk vektor mutan dengan beda terskala: $u = clip(x_a + F(x_b - x_c), 0, 1)$.

Vektor percobaan dibentuk dengan pindah silang binomial: tiap gen diambil dari mutan dengan peluang CR, dan paling sedikit satu gen dipaksa berasal dari mutan. Seleksi bersifat *greedy*: vektor percobaan menggantikan target jika lebih baik menurut aturan Deb.Pembaruan dilakukan serempak per generasi (100 evaluasi per generasi, 200 generasi).

Tabel 3.11 Parameter DE

Parameter	Nilai
Ukuran populasi	100
Faktor mutasi F	0,1
Peluang pindah silang CR	0,5
Individu awal tersemai	10 (populasi awal acak murni)

Jumlah generasi	200

Penalaan DE: F ∈ {0,3; 0,5; 0,7; 0,9} × CR ∈ {0,5; 0,7; 0,9; 1,0} (16 titik), diperluas satu kali ke F ∈ {0,1; 0,2}, CR ∈ {0,1; 0,3} (20 titik tambahan); total 36 titik × 30 seed = 1.080 run. Median R terpilih 0,4423 dibanding 0,4366 pada parameter awal ($p \approx 6\times10^{-9}$). F = 0,1 masih berada di tepi grid (nilai yang lebih kecil membuat vektor mutan nyaris tidak berbeda dari donornya), sehingga optimum F yang sebenarnya dapat lebih kecil; hal ini dicatat sebagai keterbatasan.

Tabel 3.12 Kode Satu Generasi DE

```
scores = rng.random((m, n))
scores[np.arange(m), np.arange(m)] = np.inf
a, b, c = np.argpartition(scores, kth=2, axis=1)[:,
:3].T
mutant = np.clip(x[a] + F * (x[b] - x[c]), 0.0, 1.0)
cross = rng.random((m, d)) < CR
cross[np.arange(m), rng.integers(0, d, size=m)] = True
trial = np.where(cross, mutant, x[:m])
Rt, st, vt = ev.evaluate(trial)
accept = deb_lebih_baik(Rt, vt, R[:m], viol[:m])
x[accept] = trial[accept]
```

Pada pemilihan saham, DE bekerja langsung pada kunci kontinu sehingga mutasi beda terskala tidak secara eksplisit mempertahankan kardinalitas; kardinalitas dijamin sepenuhnya oleh dekoder.

3.5. Skenario Eksperimen dan Metrik Evaluasi

Eksperimen dibagi menjadi 2 fase agar penalaan parameter tidak bercampur dengan pengujian akhir.

Fase 1: Penalaan parameter dilakukan untuk keempat algoritma dengan protokol yang sama: satu masalah representatif (jendela 1, K = 7, σ_max 1,5×), 30 run per titik grid pada seed 100–129, anggaran 20.000 evaluasi, populasi awal tersemai seperti pada Subbab 3.3. Grid kecil per algoritma mengikuti rencana penelitian (Tabel 3.13) dan diperluas satu kali bila nilai terbaik berada di tepi. Pemilihan: median R tertinggi; selisih ≤ 0,001 dianggap seri dan dipilih simpangan baku terkecil. Parameter terpilih dibekukan sebelum Fase 2 dan dibandingkan dengan parameter awal pada seed penalaan yang sama (Mann–Whitney)

Tabel 3.13 Grid dan hasil Fase 1

Algoritma	Parameter yang ditala	Titik (run)	Terpilih	Median R terpilih	Median R awal	p
GA	populasi × laju mutasi	16 (480)	pop 400, laju mutasi 2/N	0,4360	0,4315	0,005
PSO	w × c, lalu v_max	39 (1.170)	w 1,0, c 2,5, v_max 0,2	0,4396	0,4358	0,002
SA	peluang penerimaan awal (T_0) × rasio suhu akhir	12 (360)	0,8; 10^{-4}	0,4370	0,4358	0,33
DE	F × CR	36 (1.080)	F 0,1, CR 0,5	0,4423	0,4366	6×10^{-9}

Fase 2 menjalankan setiap algoritma pada 30 masalah (6 data × 5 nilai K) dengan seed 0–29 yang sama, parameter beku Fase 1, dan anggaran 20.000 evaluasi: 30 × 4 × 30 = 3.600 run (72 juta evaluasi). Hasil per run disimpan dalam hasil/csv/fase2_hasil.csv.

Tabel 3.13 Ringkasan Skenario Eksperimen

Komponen	**Nilai**
Dana awal D	Rp5.000.000
Jumlah saham N	42
Kardinalitas K	2, 3, 5, 7, 10
Konfigurasi data	5 jendela *walk-forward* + 1 kasus tetap
Batas risiko σ_max	1,5 × volatilitas *equal-weight*
Batas bobot	20% per saham untuk K ≥ 7
Anggaran evaluasi	20.000 per *run*
Ulangan	30 *seed* (0–29)

Algoritma	GA, PSO, SA, DE

Metrik evaluasi dibagi menjadi dua kelompok. Kelompok pertama dihitung pada data latih (kualitas optimasi), sedangkan kelompok kedua pada data uji (kualitas portofolio di luar sampel).

Tabel 3.14 Metrik Evaluasi

Kelompok	Metrik	Keterangan
Data latih	Nilai R terbaik (rata-rata, median, simpangan baku, min, maks)	Kualitas solusi dan konsistensi antar-seed
Data latih	Tingkat kelayakan	Proporsi run yang menghasilkan solusi memenuhi $\sigma \leq \sigma_max$
Data latih	Selisih terhadap R acuan	Jarak R terhadap nilai acuan terbaik
Data latih	Tingkat keberhasilan	Proporsi run dengan selisih ≤ 1% terhadap R acuan
Data latih	Evaluasi hingga solusi terbaik, waktu	Kecepatan konvergensi dan biaya komputasi
Data latih	Kurva konvergensi	Median dan kuartil R terbaik terhadap jumlah evaluasi
Data uji	Return total dan setara tahunan	R_uji, setara tahun = total × 252 / T
Data uji	Volatilitas, Sharpe ratio, maximum drawdown, CVaR 95%	Risiko yang terealisasi
Data uji	Realisasi risiko	Volatilitas uji dibanding σ_max
Data uji	Shrinkage	R_uji − R_latih, selisih antara hasil latih dan uji

Definisi Matrik:

- R acuan per masalah: optimum brute force untuk K = 2; untuk K ≥ 3, R terbaik yang pernah ditemukan oleh seluruh run keempat algoritma pada masalah itu.
- Selisih = R acuan − median R. Tingkat keberhasilan = proporsi run layak dengan R ≥ 0,99 × R acuan (selisih relatif ≤ 1%).
- Sharpe (data uji) = (return setara tahunan − r_f) / volatilitas uji tahunan. CVaR 95% = rata-rata 5% return harian terburuk pada periode uji.

- Shrinkage = return setara tahunan uji − R latih.

Nilai portofolio pada data uji dihitung dengan menumbuhkan setiap saham sesuai dengan return harian uji dan kas sesuai r_f, kemudian ditahan tanpa penyeimbangan ulang

R acuan diperoleh dari perhitungan penuh *(brute force)* untuk K=2, yang menjadi optimum sejati. Untuk K≥3, ruang pencarian terlalu besar untuk enumerasi sehingga acuan yang dipakai adalah solusi terbaik yang pernah ditemukan oleh seluruh algoritma pada masalah tersebut. Selisih untuk K≥3 karena itu merupakan selisih relatif terhadap yang terbaik diketahui, bukan terhadap optimum sejati.

Uji statistik deskriptif dilaporkan untuk setiap algoritma pada setiap masalah. Perbedaan antar-algoritma diuji dengan uji peringkat bertanda Wilcoxon berpasangan atas 30 masalah, dengan median R antar 30 seed sebagai satu pasangan nilai per masalah, dan koreksi Holm untuk enam pasangan algoritma. Seed yang sama pada semua algoritma memastikan setiap algoritma menghadapi kondisi acak yang setara. Uji *Mann-Whitney* dipakai untuk perbandingan antar-konfigurasi PSO (awal dan terpilih). Perbedaan dinyatakan bermakna jika p ter-koreksi <0,05. Algoritma yang unggul pada metrik latih tidak otomatis dinyatakan lebih baik: kesimpulan terakhir mempertimbangkan juga kinerja data uji dan konsistensinya antar-jendela, mengingat estimasi μ dari data historis bersifat sangat noisy sehingga solusi yang optimal pada data latih belum tentu optimal pada data uji.

3.6. Visualisasi Hasil Optimasi

Hasil eksperimen disajikan melalui modul visualisasi.py dan aplikasi web interaktif berbasis Streamlit (app.py).

Tabel 3.15 Fungsi Visualisasi

Fungsi	Isi
`plot_konvergensi`	Kurva R terbaik terhadap jumlah evaluasi (median dan kuartil antar-*seed*)
`plot_risiko_return`	Posisi portofolio pada bidang risiko–return terhadap batas σ_max
`plot_bobot`	Komposisi bobot saham dan kas
`plot_box`	Sebaran R antar-*seed* per algoritma

`plot_konvergensi_profil`	Konvergensi pada berbagai profil risiko
`plot_proses`, `plot_proses_sa`	Perilaku populasi/kawanan dan proses pendinginan SA selama pencarian
`plot_uji`	Nilai portofolio selama periode uji

Aplikasi Streamlit menyediakan sembilan tab: Ringkasan, Portofolio, Proses, Perbandingan, Data uji, Profil risiko, Hasil penelitian, Fase 2, dan Tentang. Pengguna memilih jendela data, K, modal, batas risiko, algoritma (GA, PSO, SA, DE), jumlah seed, serta parameter terpilih (Fase 1) atau parameter awal (PDF) untuk keempat algoritma. Tab Fase 2 menampilkan peringkat, uji Wilcoxon–Holm, dan sebaran hasil.

4. HASIL DAN PEMBAHASAN

4.1. Validasi *Constraint*

4.2. Analisis Hasil *Genetic Algorithm* (GA)

4.2.1. Optimasi Alokasi Dana Portofolio Saham

Pengujian algoritma *Genetic Algorithm* (GA) dilakukan pada lima skenario batas kardinalitas, yaitu K = 2, 3, 5, 7, dan 10. Setiap skenario dijalankan sebanyak 30 kali menggunakan *random seed* berbeda, dengan anggaran 20.000 evaluasi *fitness* per percobaan. Modal yang digunakan sebesar Rp5.000.000 dengan batas risiko tahunan sebesar 23,90%. Dari setiap skenario, dipilih solusi layak dengan *expected return* tahunan tertinggi berdasarkan data latih.

Tabel 4.1 Hasil Optimasi Terbaik PSO

K	Seed	Jumlah Saham	Dana Saham (Rp)	Sisa Kas (Rp)	Expected Return (%/Tahun)	Risiko (%/Tahun)
2	20	2	3.787.500	1.212.500	29,66	23,77
3	9	3	3.500.000	1.500.000	32,23	23,85
5	19	5	4.000.000	1.000.000	34,08	23,87
7	3	7	4.697.000	303.000	33,61	23,83
10	18	8	4.603.000	397.000	33,80	23,82

Berdasarkan tabel di atas, portofolio dengan *expected return* tertinggi diperoleh pada K = 5 dengan *seed* 19, yaitu sebesar 34,08% per tahun dan risiko 23,87% per tahun. Rincian pembelian saham pada portofolio tersebut disajikan dalam Tabel 4.2.

4.2.2. Analisis Karakteristik Pencarian (*Crossover* dan Mutasi) pada GA

P

4.3. Analisis Hasil *Particle Swarm Optimization* (PSO)

4.3.1. Optimasi Alokasi Dana Portofolio Saham

Pengujian algoritma *Particle Swarm Optimization* (PSO) dilakukan pada lima skenario batas kardinalitas, yaitu K = 2, 3, 5, 7, dan 10. Setiap skenario dijalankan sebanyak 30 kali menggunakan *random seed* berbeda, dengan anggaran 20.000 evaluasi *fitness* per percobaan. Modal yang digunakan sebesar Rp5.000.000 dengan batas risiko tahunan sebesar

23,90%. Dari setiap skenario, dipilih solusi layak dengan *expected return* tahunan tertinggi berdasarkan data latih.

Tabel 4.1 Hasil Optimasi Terbaik PSO

K	Seed	Jumlah Saham	Dana Saham (Rp)	Sisa Kas (Rp)	Expected Return (%/Tahun)	Risiko (%/Tahun)
2	20	2	3.787.500	1.212.500	29,66	23,77
3	9	3	3.500.000	1.500.000	32,23	23,85
5	19	5	4.000.000	1.000.000	34,08	23,87
7	3	7	4.697.000	303.000	33,61	23,83
10	18	8	4.603.000	397.000	33,80	23,82

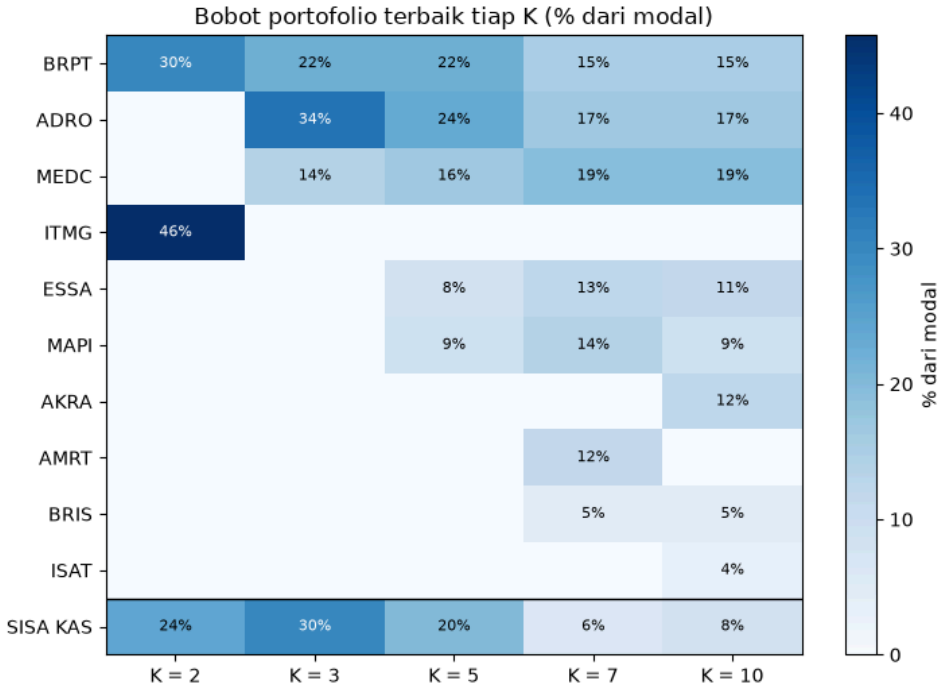
Berdasarkan tabel di atas, portofolio dengan *expected return* tertinggi diperoleh pada K = 5 dengan *seed* 19, yaitu sebesar 34,08% per tahun dan risiko 23,87% per tahun. Rincian pembelian saham pada portofolio tersebut disajikan dalam Tabel 4.2.

Tabel 4.2 Rincian Alokasi Dana Saham Portofolio Terbaik PSO

Saham	Jumlah Lot	Biaya Pembelian (Rp)	Bobot Modal (%)
ADRO	7	1.183.000	23,66
BRPT	3	1.125.000	22,50
MEDC	6	822.000	16,44
MAPI	4	450.000	9,00
ESSA	6	420.000	8,40
Total	**26**	**4.000.000**	**80,00**
Sisa Kas	**-**	**1.000.000**	**20,00**

PSO mengalokasikan Rp4.000.000 atau 80% dari modal untuk membeli lima saham, sedangkan Rp1.000.000 atau 20% dipertahankan sebagai kas. Alokasi terbesar diberikan kepada ADRO sebesar Rp1.183.000 (23,66%), diikuti BRPT sebesar Rp1.125.000 (22,50%) dan MEDC sebesar Rp822.000 (16,44%). Berdasarkan perhitungan kontribusi return pada notebook, BRPT memberikan kontribusi terbesar terhadap

expected return portofolio, yaitu 11,85 poin persentase, diikuti ADRO sebesar 9,12 poin persentase dan MEDC sebesar 7,02 poin persentase. Dengan demikian, saham dengan alokasi dana terbesar tidak selalu memberikan kontribusi return tertinggi.

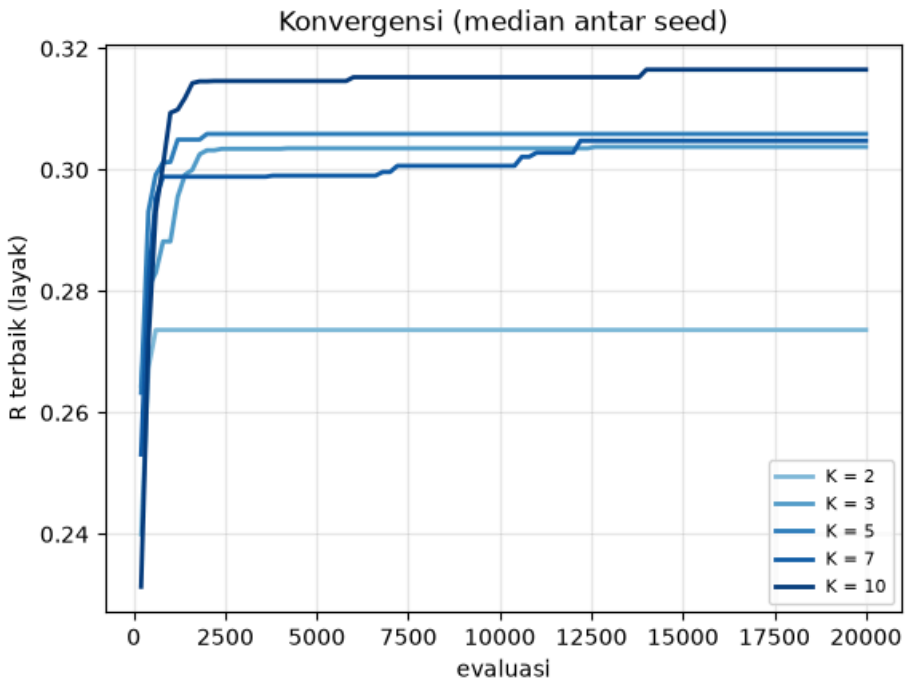


Gambar 4.1 Komposisi Bobot Saham dan Kas

Gambar 4.1 menunjukkan perbedaan komposisi saham dan kas pada setiap skenario kardinalitas. Pada K=5, PSO mengalokasikan 80% modal untuk lima saham dan mempertahankan 20% sebagai kas. Sementara itu, pada K=7 dan K=10, bobot setiap saham tidak melebihi batas 20% yang ditetapkan.

4.3.2. Analisis Konvergensi dan Konsistensi Hasil

Analisis konvergensi dilakukan untuk mengamati perkembangan *expected return* terbaik selama proses optimasi DE. Gambar 4.2 memperlihatkan median hasil konvergensi dari 30 percobaan pada setiap skenario kardinalitas.



Gambar 4.2 Konvergensi PSO pada Skenario Kardinalitas

Berdasarkan Gambar 4.2, *expected return* terbaik meningkat pada tahap awal pencarian, kemudian cenderung stabil meskipun evaluasi masih berlangsung. Pola tersebut menunjukkan bahwa sebagian besar perbaikan solusi ditemukan sebelum seluruh anggaran evaluasi digunakan. Konsistensi hasil dianalisis berdasarkan 30 percobaan dengan *random seed* berbeda pada setiap K. Ringkasan hasil pengujian disajikan pada Tabel 4.3.

Tabel 4.3 Kinerja PSO pada 30 Percobaan

K	**Median Expected Return (%/Tahun)**	**Simpangan Baku (Poin Persentase)**	**Kelayakan (%)**	**Median Waktu (Detik)**
2	27,36	2,49	100	0,35
3	30,38	2,57	100	0,35
5	30,59	2,74	100	0,34
7	30,48	2,62	100	0,47
10	31,65	2,45	100	0,47

Tabel di atas menunjukkan bahwa median *expected return* tertinggi diperoleh pada K = 10 sebesar 31,65%, sedangkan yang terendah terdapat

pada K = 2 sebesar 27,36%. Simpangan baku berkisar antara 2,45 hingga 2,74 poin persentase, dengan variasi hasil terbesar pada K = 5. Seluruh 150 percobaan menghasilkan portofolio yang memenuhi batasan optimasi, dengan waktu komputasi yang tercatat sekitar 0,34–0,47 detik per percobaan.

Untuk memeriksa kualitas pencarian PSO, dilakukan perbandingan dengan solusi *brute force* pada K = 2 menggunakan tiga periode data. Hasilnya disajikan pada Tabel 4.4.

Tabel 4.4 Hasil Verifikasi PSO terhadap Brute Force pada K=2

Periode Data	Return Optimum Brute Force (%)	Return PSO Terbaik (%)	Median Return PSO (%)	Keberhasilan Gap ≤ 1%
Kasus tetap	29,66	29,66	27,36	47%
Jendela 3	28,17	28,17	25,21	37%
Jendela 5	51,14	51,14	49,75	47%

Hasil pada Tabel 4.4 menunjukkan bahwa PSO berhasil menemukan solusi optimum *brute force* pada percobaan terbaik di ketiga periode. Namun, tingkat keberhasilan untuk memperoleh solusi dengan selisih maksimal 1% dari optimum hanya mencapai 37–47% dari 30 percobaan. Selain itu, sebagian besar percobaan menemukan solusi terbaiknya sebelum menggunakan separuh anggaran evaluasi. Temuan ini menunjukkan adanya kecenderungan konvergensi dini, yaitu kondisi ketika pencarian tidak lagi menghasilkan perbaikan meskipun evaluasi masih tersedia.

4.3.3. Evaluasi Kinerja Portofolio pada Data Uji

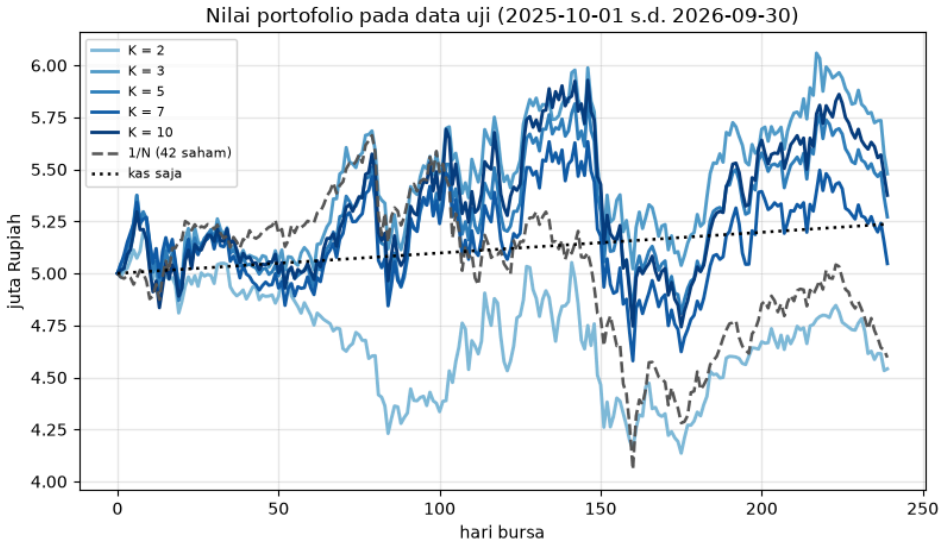
Evaluasi dilakukan terhadap portofolio terbaik dari setiap skenario kardinalitas menggunakan data uji periode 1 Oktober 2025 hingga 30 September 2026. Pengujian menerapkan strategi *buy-and-hold*, yaitu mempertahankan alokasi saham hasil optimasi tanpa melakukan penyesuaian selama periode pengujian. Hasil evaluasi disajikan pada Tabel 4.5.

Tabel 4.5 Hasil Evaluasi Portofolio PSO pada Data Uji

K	Return Uji (%/Tahun)	Volatilitas (%/Tahun)	Max Drawdown (%)	Nilai Akhir (Rp)
2	-9,7	23,4	-20,5	4.541.291

3	10,1	24,6	-16,1	5.478.374
5	5,7	25,3	-17,8	5.271.286
7	1,0	26,4	-18,7	5.047.001
10	7,9	25,9	-20,0	5.375.436

Berdasarkan tabel di atas, portofolio K = 3 menghasilkan return pengujian tertinggi sebesar 10,1% per tahun dengan nilai akhir Rp5.478.374. Sebaliknya, K = 2 menghasilkan return negatif sebesar -9,7% per tahun. Portofolio K = 5, yang memiliki *expected return* tertinggi pada data latih sebesar 34,08%, hanya memperoleh return pengujian sebesar 5,7% per tahun. Hasil tersebut menunjukkan bahwa portofolio dengan *expected return* tertinggi pada data latih belum tentu memberikan kinerja terbaik pada data uji. Selain itu, volatilitas pengujian pada K = 3, 5, 7, dan 10 melebihi batas risiko latih sebesar 23,90%, sedangkan K = 2 tetap berada di bawah batas tersebut.



Gambar 4.3 Perkembangan Nilai Portofolio PSO pada Data Uji

Gambar 4.3 menunjukkan perubahan nilai portofolio selama periode pengujian. Portofolio K=3 menghasilkan nilai akhir tertinggi, sedangkan K=2 mengalami penurunan nilai investasi. Perbedaan pergerakan tersebut menunjukkan bahwa kombinasi saham hasil PSO memiliki kinerja yang berbeda pada data uji.

4.4. Analisis Hasil *Simulated Annealing* (SA)

4.4.1. Optimasi Alokasi Dana Portofolio

4.4.2. Analisis Efisiensi Penurunan Suhu (Cooling Schedule) terhadap Konvergensi

4.5. Analisis Hasil *Differential Evolution* (DE)

4.5.1. Optimasi Alokasi Dana Portofolio Saham

Pengujian algoritma *Differential Evolution* (DE) dilakukan pada lima skenario batas kardinalitas, yaitu K = 2, 3, 5, 7, dan 10. Setiap skenario dijalankan sebanyak 30 kali menggunakan *random seed* yang berbeda, dengan anggaran 20.000 evaluasi *fitness* per percobaan. Modal yang digunakan sebesar Rp5.000.000 dengan batas risiko tahunan sebesar 23,90%. Dari setiap skenario, dipilih solusi layak dengan *expected return* tahunan tertinggi berdasarkan data latih.

Tabel 4.1 Hasil Optimasi Terbaik DE

K	Seed	Jumlah Saham	Dana Saham (Rp)	Sisa Kas (Rp)	Expected Return (%/Tahun)	Risiko (%/Tahun)
2	7	2	3.787.500	1.212.500	29,66	23,77
3	0	3	3.500.000	1.500.000	32,23	23,85
5	6	5	4.042.500	957.500	33,95	23,80
7	13	7	4.584.500	415.500	34,09	23,88
10	29	7	4.635.500	364.500	34,13	23,88

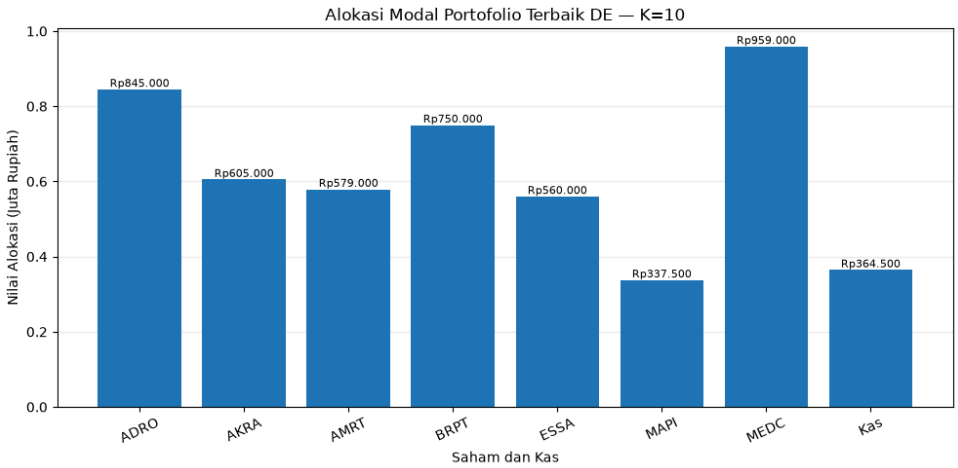
Berdasarkan tabel di atas, portofolio dengan *expected return* tertinggi diperoleh pada K = 10 dengan *seed* 29, yaitu sebesar 34,13% per tahun dan risiko sebesar 23,88% per tahun. Rincian pembelian saham pada portofolio tersebut disajikan dalam Tabel 4.2.

Tabel 4.2 Rincian Alokasi Dana Saham Portofolio Terbaik DE

Saham	Jumlah Lot	Biaya Pembelian (Rp)	Bobot Modal (%)
MEDC	7	959.000	19,18
ADRO	5	845.000	16,90
BRPT	2	750.000	15,00
AKRA	5	605.000	12,10

AMRT	3	579.000	11,58
ESSA	8	560.000	11,20
MAPI	3	337.500	6,75
Total	**33**	**4.635.500**	**92,71**
Sisa Kas	**-**	**364.500**	**7,29**

DE mengalokasikan Rp4.635.500 atau 92,71% dari modal untuk membeli tujuh saham, sedangkan Rp364.500 atau 7,29% dipertahankan sebagai kas. Alokasi terbesar diberikan kepada MEDC sebesar Rp959.000 (19,18% dari modal), diikuti ADRO sebesar Rp845.000 (16,90%) dan BRPT sebesar Rp750.000 (15,00%). Seluruh bobot saham memenuhi batas maksimum 20% yang berlaku pada skenario K = 10.



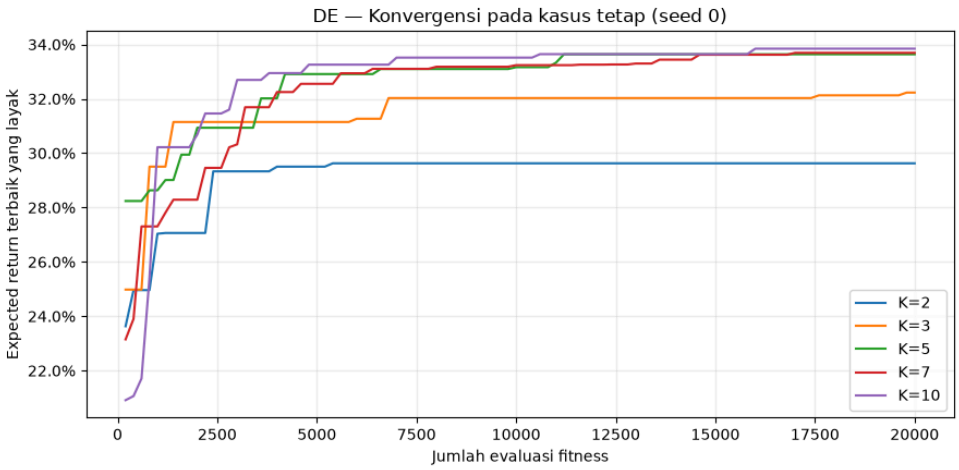
Gambar 4.1 Alokasi Modal Portofolio Terbaik DE

Gambar 4.1 memperlihatkan pembagian modal pada setiap saham terpilih beserta sisa kas. Hasil tersebut menunjukkan bahwa DE dapat menghasilkan alokasi pembelian dalam satuan lot dengan tetap memenuhi batas modal, risiko, dan kardinalitas. Namun, *expected return* sebesar 34,13% merupakan estimasi berdasarkan data latih, bukan keuntungan aktual pada periode pengujian.

4.5.2. Analisis Konvergensi dan Konsistensi Hasil

Analisis konvergensi dilakukan untuk mengamati perkembangan *expected return* terbaik selama proses optimasi DE. Grafik pada Gambar 4.2 menunjukkan *expected return* terbaik meningkat selama proses pencarian hingga mencapai kondisi relatif stabil. Kurva pada setiap skenario memperlihatkan bahwa perbaikan solusi dapat muncul setelah sejumlah evaluasi tanpa peningkatan. Perbedaan nilai akhir antarkurva

juga memperlihatkan pengaruh batas kardinalitas terhadap kualitas solusi yang ditemukan DE.



Gambar 4.2 Konvergensi DE pada Skenario Kardinalitas

Selain konvergensi, konsistensi hasil dievaluasi melalui 30 percobaan dengan *random seed* berbeda pada setiap skenario. Ringkasan median *expected return*, simpangan baku, tingkat kelayakan, dan waktu komputasi disajikan pada Tabel 4.3.

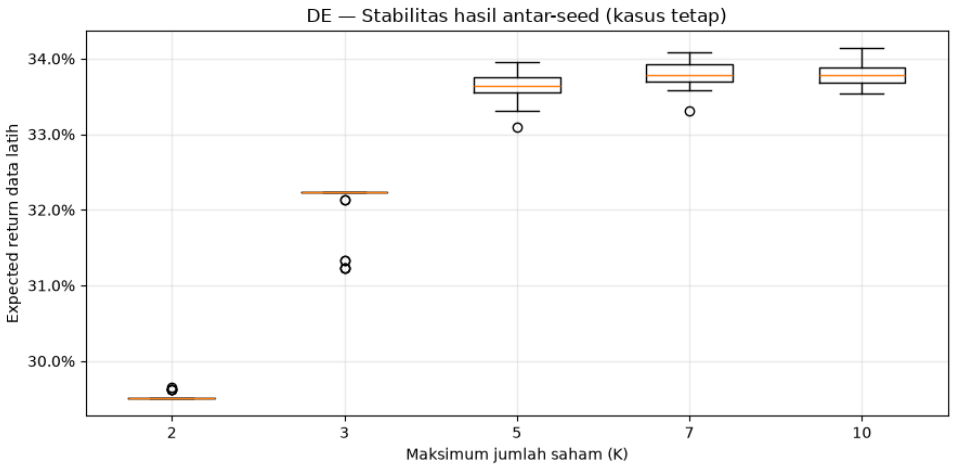
Tabel 4.3 Kinerja DE pada 30 Percobaan

K	Median Expected Return (%/Tahun)	Simpangan Baku (Poin Persentase)	Kelayakan (%)	Median Waktu (Detik)
2	29,50	0,05	100	0,332
3	32,23	0,36	100	0,352
5	33,64	0,18	100	0,328
7	33,78	0,15	100	0,435
10	33,78	0,16	100	0,407

Tabel di atas menunjukkan bahwa median *expected return* meningkat dari 29,50% pada K = 2 menjadi 33,78% pada K = 7 dan 10. Simpangan baku pada seluruh skenario berada antara 0,05 hingga 0,36 poin persentase. K = 2 memiliki variasi hasil paling rendah, sedangkan K = 3 menunjukkan variasi paling tinggi. Seluruh percobaan menghasilkan solusi yang memenuhi batasan optimasi, dengan tingkat kelayakan 100%.

Dari segi waktu komputasi, median waktu setiap percobaan berada pada kisaran 0,328–0,435 detik. Hasil ini menunjukkan bahwa DE dapat

menyelesaikan proses optimasi dengan anggaran 20.000 evaluasi *fitness* dalam waktu relatif singkat pada konfigurasi pengujian yang digunakan.



Gambar 4.3 Distribusi Expected Return DE pada 30 Percobaan

Gambar 4.3 memperlihatkan distribusi *expected return* dari 30 percobaan pada setiap skenario kardinalitas. Sebaran hasil yang relatif sempit menunjukkan bahwa DE menghasilkan nilai *expected return* yang cukup konsisten meskipun menggunakan *random seed* berbeda. Namun, tingkat konsistensi tersebut tidak selalu sama pada setiap K, sebagaimana terlihat dari perbedaan simpangan baku pada Tabel 4.3.

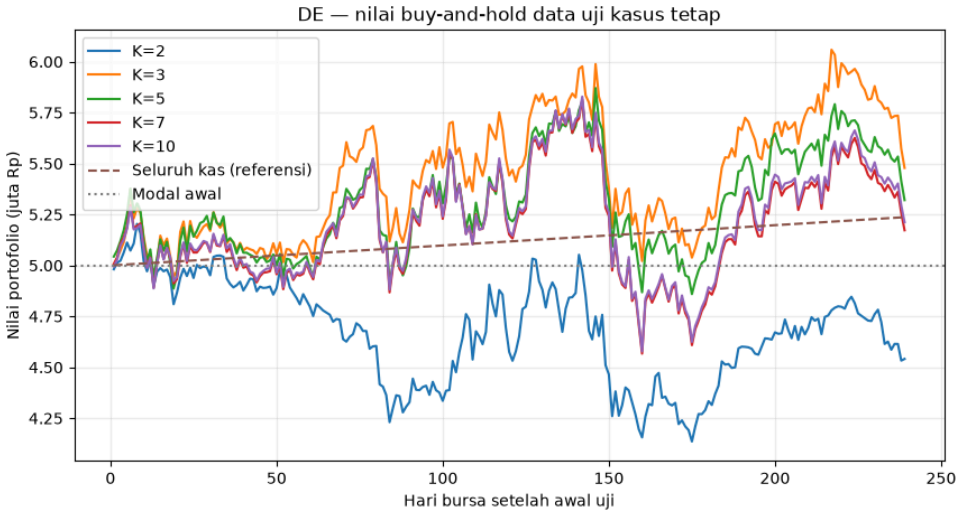
4.5.3. Evaluasi Kinerja Portofolio Data Uji

Evaluasi dilakukan terhadap portofolio terbaik dari setiap skenario kardinalitas menggunakan data uji periode 1 Oktober 2025 hingga 30 September 2026. Pengujian menerapkan strategi *buy-and-hold*, yaitu mempertahankan alokasi saham hasil optimasi tanpa melakukan penyesuaian selama periode pengujian. Hasil evaluasi disajikan pada Tabel 4.4.

Tabel 4.4 Hasil Evaluasi Portofolio DE pada Data Uji

K	Return Uji (%/Tahun)	Volatilitas (%/Tahun)	Max Drawdown (%)	Nilai Akhir (Rp)
2	-9,67	23,36	-20,53	4.541.291
3	10,09	24,64	-16,14	5.478.374
5	6,76	25,14	-17,23	5.320.581
7	3,64	26,41	-21,46	5.172.536
10	4,47	26,37	-21,45	5.211.997

Berdasarkan tabel di atas, portofolio K = 3 menghasilkan kinerja pengujian tertinggi dengan return tahunan sebesar 10,09% dan nilai akhir Rp5.478.374. Sebaliknya, K = 2 menghasilkan return negatif sebesar -9,67%. Portofolio K = 10, yang memiliki *expected return* tertinggi pada data latih, hanya memperoleh return pengujian sebesar 4,47% per tahun. Hasil tersebut menunjukkan bahwa portofolio dengan *expected return* tertinggi pada data latih belum tentu menghasilkan kinerja terbaik pada data uji. Selain itu, volatilitas pengujian pada K = 3, 5, 7, dan 10 melebihi batas risiko latih sebesar 23,90%, sedangkan K = 2 tetap berada di bawah batas tersebut.



Gambar 4.4 Perkembangan Nilai Portofolio DE pada Data Uji

Gambar 4.4 menunjukkan perubahan nilai portofolio selama periode pengujian. Perbedaan pergerakan nilai investasi pada setiap K memperlihatkan bahwa kombinasi saham yang dihasilkan DE memiliki kinerja berbeda ketika diterapkan pada data di luar periode optimasi. Untuk mengevaluasi hasil pada periode yang berbeda, dilakukan pengujian *walk-forward* menggunakan tiga jendela data. Setiap jendela diuji pada lima skenario kardinalitas dengan 10 *random seed* per skenario.

Tabel 4.5 Median Return Tahunan Data Uji

K	Jendela 1	Jendela 2	Jendela 3
2	5,05	-14,66	0,72
3	11,90	-16,83	-3,19
5	4,50	-15,45	-14,83
7	13,60	-10,43	10,83

10	12,18	-12,98	14,17

Tabel 4.5 menunjukkan bahwa seluruh skenario menghasilkan median return positif pada jendela pertama, tetapi mengalami return negatif pada jendela kedua. Pada jendela ketiga, K = 7 dan K = 10 kembali menghasilkan return positif, masing-masing sebesar 10,83% dan 14,17%. Hasil *walk-forward* menunjukkan bahwa kinerja portofolio DE bervariasi antarperiode pengujian. Meskipun seluruh percobaan menghasilkan solusi yang memenuhi batasan pada data latih, hasil pada data uji tetap dipengaruhi oleh perubahan kondisi pasar.

4.6. Komparasi & Diskusi Lintas Algoritma

4.6.1. Perbandingan Kinerja Portofolio Optimal (*Expected Return, Risiko/Variance, dan Sharpe Ratio*)

4.6.2. Perbandingan Kecepatan Komputasi dan Stabilitas Konvergensi Algoritma

4.6.3. Analisis Konvergensi Gabungan

4.6.3.1. Skenario Profil Risiko Konservatif

4.6.3.2. Skenario Profil Risiko Moderat

4.6.3.3. Skenario Prodil Risiko Agresif

4.7. Implikasi Manajerial & Strategi Investasi

<<(Menggantikan "Implikasi Operasional", bagian ini membahas rekomendasi praktis bagi investor atau manajer investasi berdasarkan algoritma yang paling optimal). >>

5. PENUTUP

5.1. Kesimpulan

5.2. Saran

6. LAMPIRAN

Link Github : https://github.com/hanscakrawangsa15/OptimasiPortofolioSaham

DAFTAR PUSTAKA

Ashraf, Z., Shahid, M., Sami, L., Hasan, F., & Shamim, M. (2026). Invasive weed optimization based metaheuristic approach for solving constrained risk budgeted portfolio selection problem. *Alexandria Engineering Journal, 135*, 273–317. https://doi.org/10.1016/j.aej.2025.12.067

Barroso, P., & Saxena, K. (2022). Lest we forget: Learn from out-of-sample forecast errors when optimizing portfolios. *The Review of Financial Studies, 35*(3), 1222–1278. https://doi.org/10.1093/rfs/hhab041

Bursa Efek Indonesia. (2024). *Panduan dan metodologi indeks IDX80, LQ45 dan IDX30*. Lampiran Pengumuman BEI No. Peng-00058/BEI.POP/03-2024, 27 Maret 2024. Dokumen resmi BEI

Bursa Efek Indonesia. (t.t.-a). *Indeks*. Diakses pada 20 Oktober 2026. https://www.idx.co.id/id/produk/indeks

Bursa Efek Indonesia. (t.t.-b). *Jam dan mekanisme perdagangan*. Diakses pada 20 Oktober 2026. https://www.idx.co.id/id/produk/mekanisme-dan-jam-perdagangan

Dahlquist, J., & Knight, R. (2022). *Principles of finance*. OpenStax. Bagian 1.7: Financial Instruments

Deb, K. (2000). An efficient constraint handling method for genetic algorithms. *Computer Methods in Applied Mechanics and Engineering, 186*(2–4), 311–338. https://doi.org/10.1016/S0045-7825(99)00389-8

Erwin, K., & Engelbrecht, A. (2023). Meta-heuristics for portfolio optimization. *Soft Computing, 27*, 19045–19073. https://doi.org/10.1007/s00500-023-08177-x

Katoch, S., Chauhan, S. S., & Kumar, V. (2021). A review on genetic algorithm: Past, present, and future. *Multimedia Tools and Applications, 80*, 8091–8126. https://doi.org/10.1007/s11042-020-10139-6

Kennedy, J., & Eberhart, R. (1995). Particle swarm optimization. Dalam *Proceedings of ICNN'95—International Conference on Neural Networks* (Vol. 4, hlm. 1942–1948). IEEE. https://doi.org/10.1109/ICNN.1995.488968

Kirkpatrick, S., Gelatt, C. D., Jr., & Vecchi, M. P. (1983). Optimization by simulated annealing. *Science, 220*(4598), 671–680. https://doi.org/10.1126/science.220.4598.671

Palomar, D. P. (2025). *Portfolio optimization: Theory and application*. Cambridge University Press. https://doi.org/10.1017/9781009428095

Storn, R., & Price, K. (1997). Differential evolution—A simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization, 11*, 341–359. https://doi.org/10.1023/A:1008202821328